

FASTCAMP DE DADOS SINTÉTICOS

Domain gap (I)

Randomização de domínio, transferência sim-to-real
e adaptação de domínio

Autor	Adriano César Santana
Atividade	4 - Leitura: Domain gap (I)
Material	Três artigos científicos sobre transferência de dados sintéticos para o mundo real
Data	23 de julho de 2026

Ideia central

O *domain gap* pode ser reduzido por duas estratégias complementares: ampliar deliberadamente a diversidade da simulação para tornar o mundo real apenas mais uma variação possível e alinhar, com dados reais não rotulados ou poucos dados rotulados, as representações aprendidas nos dois domínios.

1. Introdução

O uso de imagens sintéticas elimina parte do custo de coleta e anotação, mas cria um desafio: as distribuições visual e estatística do simulador não coincidem integralmente com as do ambiente real. Diferenças de textura, iluminação, câmera, ruído, geometria, contexto e frequência dos objetos podem levar a rede a aprender atalhos que funcionam na simulação e falham na implantação. Esse deslocamento é denominado *domain gap* ou *reality gap*.

Os três artigos analisados apresentam uma evolução de soluções. Tobin et al. (2017) demonstram que renderizações de baixa fidelidade, mas intensamente variadas, podem produzir transferência direta para uma tarefa robótica. Tremblay et al. (2018) ampliam a randomização de domínio para detecção de automóveis e mostram o ganho da combinação entre pré-treinamento sintético e ajuste com imagens reais. Zhang et al. (2019) tratam a segmentação de instâncias, alinhando de forma adversarial características sintéticas e reais em diferentes níveis da rede.


2. Conceitos fundamentais

2.1 Domínio de origem e domínio-alvo

O conjunto sintético constitui o **domínio de origem**, normalmente abundante e perfeitamente anotado. As imagens reais constituem o **domínio-alvo**, no qual o modelo será utilizado. A transferência é bem-sucedida quando as características aprendidas no domínio de origem continuam úteis diante da distribuição do domínio-alvo.

2.2 Randomização de domínio

A randomização de domínio não procura reproduzir uma única realidade com máxima fidelidade. Ela varia amplamente fatores como pose, posição, textura, iluminação, plano de fundo, câmera, escala, oclusões e objetos distratores. A hipótese é que, se a distribuição simulada for suficientemente diversa, o cenário real será percebido pela rede como uma variação já contemplada.



Fluxo visual: a diversidade planejada força o modelo a privilegiar características estáveis, mas a transferência somente é comprovada por avaliação no domínio real.

2.3 Adaptação de domínio

A adaptação de domínio utiliza informações do domínio-alvo para aproximar as representações dos dois conjuntos. Ela pode empregar poucos exemplos reais anotados para ajuste fino ou imagens reais não rotuladas em treinamento adversarial. Nesse último caso, discriminadores tentam reconhecer a origem das características, enquanto a rede aprende representações que dificultam essa distinção.

3. Síntese dos três artigos

3.1 Tobin et al. (2017): transferência direta para robótica

O estudo treina detectores de posição de objetos utilizando somente imagens simuladas com texturas não realistas. São randomizados câmera, iluminação, posição do objeto, texturas e distratores. Em imagens reais, os detectores localizaram objetos com erro médio próximo de **1,5 cm**, mantendo robustez a desordem e oclusão parcial, e foram empregados em demonstrações de prensão robótica.

O estudo de ablação mostra que a diversidade precisa ser suficiente: o desempenho cai acentuadamente com menos de mil texturas, melhora até aproximadamente 50 mil amostras e se torna frágil a distratores quando eles não aparecem no treinamento. O resultado reforça que a variável decisiva não é o fotorrealismo isolado, mas a cobertura dos fatores que mudarão no ambiente real.

3.2 Tremblay et al. (2018): detecção e estratégia híbrida

O segundo artigo leva a técnica à detecção de automóveis em imagens reais do KITTI. Os autores geram cenas com objetos, fundos, iluminação, pontos de vista, texturas e formas distratoras randomizados. O detector treinado apenas com esse conjunto alcança resultados competitivos, e o ajuste fino com imagens reais supera em **2,1 pontos percentuais** o treinamento feito somente com as imagens reais disponíveis.

As ablações indicam que textura, fundo e distratores exercem papéis distintos. Remover texturas aleatórias reduz a precisão; retirar distratores também prejudica o resultado. O artigo ainda alerta que congelar camadas pré-treinadas pode impedir a rede de se adaptar aos padrões incomuns das imagens randomizadas.

3.3 Zhang et al. (2019): adaptação para segmentação de instâncias

O terceiro trabalho parte de uma Mask R-CNN treinada com anotações sintéticas e utiliza imagens reais sem rótulos para reduzir o desalinhamento entre domínios. Três módulos de adaptação de características atuam em níveis complementares: global da imagem (GFAM), local da instância (LFAM) e sutil da máscara (SFAM). O treinamento adversarial torna as representações menos identificáveis como sintéticas ou reais.

Na transferência Virtual KITTI → Cityscapes, a combinação dos três módulos alcança **46,6% de AP50** em segmentação, ganho de **4,5 pontos percentuais** sobre a linha de base. Na transferência SYNTHIA → Cityscapes, o método atinge **33,2% de mAP** em detecção. Os resultados mostram que tarefas de precisão por pixel demandam alinhamento em mais de um nível.

4. Comparação das abordagens

Tobin et al.	Localização e prensão	Randomização ampla	Somente teste	Transferência direta com erro ~1,5 cm
Tremblay et al.	Detecção de carros	Randomização + ajuste fino	Treino e teste	Híbrido supera real isolado em 2,1 p.p.
Zhang et al.	Segmentação de instâncias	Adaptação adversarial multinível	Treino sem rótulos e teste	Alinhamento melhora AP50 em 4,5 p.p.

5. Principais conhecimentos e insights

- **Diversidade pode ser mais útil que fotorrealismo:** imagens pouco realistas podem transferir bem quando cobrem as variações relevantes e impedem dependência de detalhes do renderizador.
- **Randomizar não significa variar sem critério:** é necessário definir faixas coerentes com a operação, contemplando câmera, iluminação, oclusão, contexto, frequência e casos raros.
- **A validação sintética é insuficiente:** o próprio estudo de Tobin et al. observa baixa relação entre o desempenho na validação simulada e no teste real. O conjunto real deve permanecer separado.
- **Dados sintéticos e reais são complementares:** o grande volume sintético ajuda a formar a representação; poucos dados reais podem calibrar ou adaptar o modelo; dados reais independentes confirmam a generalização.
- **A adaptação precisa acompanhar a tarefa:** detecção e segmentação não dependem apenas de características globais. Objetos, regiões propostas e máscaras também podem carregar sinais específicos do domínio.

6. Implicações práticas

Definir o alvo real	Registrar câmeras, distâncias, iluminação, fundos, oclusões, classes e condições de falha.
Planejar a randomização	Variar fatores causais e de aparência; incluir distratores e casos extremos plausíveis.
Criar conjuntos separados	Manter treino sintético, ajuste real e teste real independente, evitando vazamento.
Executar ablações	Remover uma variação por vez para identificar o que realmente sustenta a transferência.
Fechar o ciclo	Transformar falhas reais em novos cenários sintéticos e repetir treinamento e validação.

7. Reflexão crítica

Os artigos demonstram que superar o *domain gap* não depende de uma única receita. Quando a tarefa e o cenário permitem, randomização suficiente pode produzir transferência direta. Quando há alguns dados reais, o ajuste fino tende a elevar o desempenho. Para tarefas mais sensíveis, como segmentação por instância, alinhar representações sintéticas e reais em vários níveis oferece uma alternativa capaz de explorar imagens reais sem anotação.

A conclusão prática é que o simulador deve ser tratado como um gerador de hipóteses sobre a realidade. Cada falha real revela uma dimensão ausente ou mal representada e pode orientar uma nova rodada de geração. Assim, o processo mais robusto é iterativo e orientado por erros, não apenas pelo volume.

8. Conclusão

A randomização de domínio transforma a imperfeição da simulação em diversidade de treinamento, e a adaptação de domínio utiliza evidências reais para reduzir diferenças residuais. Em conjunto, os três artigos sustentam uma estratégia progressiva: iniciar com variações sintéticas amplas, medir no mundo real, incorporar poucos dados reais quando disponíveis e aplicar alinhamento de características quando a tarefa exigir. O objetivo não é eliminar completamente a diferença entre os domínios, mas aprender representações que permaneçam úteis apesar dela.

Referências

- TOBIN, J. et al. *Domain Randomization for Transferring Deep Neural Networks from Simulation to the Real World*. IEEE/RSJ IROS, 2017.
- TREMBLAY, J. et al. *Training Deep Networks with Synthetic Data: Bridging the Reality Gap by Domain Randomization*. CVPR Workshops, 2018.
- ZHANG, X. et al. *Synthetic-to-Real Domain Adaptation for Object Instance Segmentation*. International Joint Conference on Neural Networks (IJCNN), 2019.